

Trabajo Practico N° 2

Minería de datos

Objetivo

El objetivo de este trabajo práctico es integrar los conocimientos adquiridos en las unidades 4 y 5 en dos problemas reales: uno de **regresión**, asociado al comportamiento financiero de 1000 empresas (estimación de la variable *Profit*), y otro de **clasificación**, asociado a la predicción del tipo de droga farmacéutica (estimación de la variable *Droga*).

Actividades

Parte A – Regresión (dataset 1000 Companies.csv)

1. **Preparación de datos.** Descargar el conjunto de datos *1000_Companies.csv*¹. Realizar un análisis exploratorio de datos (EDA): visualizar distribuciones, detectar valores faltantes, analizar correlaciones entre variables. Limpiar el conjunto de datos (manejar valores faltantes, tratar outliers) si es necesario. Codificar variables categóricas (si corresponde). Normalizar o estandarizar las características numéricas. Generar dos particiones del dataset: una con proporción 80/20 y otra con proporción 70/30 (entrenamiento/test). Utilizar *random_state=63* para garantizar la reproducibilidad de los resultados.
2. **Árboles de decisión para regresión.** Realizar la estimación de la variable *Profit* utilizando árboles de decisión (DecisionTreeRegressor). Explorar sistemáticamente los siguientes hiperparámetros, probando al menos 3 valores para cada uno: máxima profundidad (*max_depth*), número mínimo de observaciones por hoja (*min_samples_leaf*) y número mínimo de observaciones para realizar una separación (*min_samples_split*). Justificar la elección del mejor modelo. Graficar el árbol obtenido con la mejor configuración. Reportar los resultados sobre **ambos conjuntos de test** (80/20 y 70/30) utilizando las siguientes métricas: Error Absoluto Medio (MAE), Error Cuadrático Medio (MSE) y Raíz del Error Cuadrático Medio (RMSE).

Parte B – Clasificación (dataset drugType.csv)

3. **Preparación de datos.** Descargar el conjunto de datos *drugType.csv*². Realizar un análisis exploratorio de datos (EDA): visualizar distribuciones, detectar valores faltantes, analizar correlaciones y la distribución de clases de la variable objetivo *Droga* (verificar si existe desbalance). Limpiar el conjunto de datos (manejar valores faltantes, tratar outliers) si es necesario. Codificar variables categóricas (si corresponde). Normalizar o estandarizar las características numéricas. Generar dos particiones del dataset: una con proporción 80/20 y otra con proporción 70/30 (entrenamiento/test), utilizando *random_state=63* y estratificación por la variable objetivo.
4. **Árboles de decisión para clasificación.** Realizar la estimación de la variable *Droga* utilizando árboles de decisión (DecisionTreeClassifier). Explorar sistemáticamente los siguientes hiperparámetros, probando al menos 3 valores

¹<https://www.kaggle.com/datasets/subhamp7/company-profit-and-expenditures>

²<https://www.kaggle.com/datasets/lykin22/drug-data>

Trabajo Practico N° 2

Minería de datos

para cada uno: máxima profundidad (*max_depth*), número mínimo de observaciones por hoja (*min_samples_leaf*) y número mínimo de observaciones para realizar una separación (*min_samples_split*). Graficar el árbol obtenido con la mejor configuración **antes y después** de aplicar post-poda (*ccp_alpha*). Justificar el valor de *ccp_alpha* seleccionado. Reportar los resultados sobre ambos conjuntos de test (80/20 y 70/30) utilizando: Precisión (Precision), Exhaustividad (Recall) y Exactitud (Accuracy), reportando los valores **macro** para Precisión y Exhaustividad. Incluir además la matriz de confusión.

5. **Bayes Ingenuo.** Realizar la estimación de la variable *Droga* utilizando Naive Bayes. Para ello, discretizar los atributos continuos mediante el método de *equal-frequency* (*cuantiles*) con al menos 3 y 5 intervalos, y aplicar CategoricalNB o MultinomialNB sobre los datos discretizados. Alternativamente, puede utilizarse GaussianNB directamente sobre los datos continuos y comparar ambos enfoques. Reportar los resultados sobre ambos conjuntos de test (80/20 y 70/30) utilizando: Precisión (Precision), Exhaustividad (Recall) y Exactitud (Accuracy), reportando los valores **macro** para Precisión y Exhaustividad. Incluir además la matriz de confusión.
6. **k-NN.** Realizar la estimación de la variable *Droga* utilizando k-NN (KNeighborsClassifier). Explorar sistemáticamente los siguientes hiperparámetros: cantidad de vecinos (*n_neighbors*: probar al menos 5 valores, por ejemplo, k = 1, 3, 5, 7, 9) y métrica de distancia (*metric*: euclidean, manhattan). Reportar los resultados sobre ambos conjuntos de test (80/20 y 70/30) utilizando: Precisión (Precision), Exhaustividad (Recall) y Exactitud (Accuracy), reportando los valores **macro** para Precisión y Exhaustividad. Incluir además la matriz de confusión.
7. **Comparación de modelos.** Realizar una tabla comparativa de los tres modelos de clasificación (árbol de decisión, Bayes Ingenuo y k-NN) sobre ambos conjuntos de test, indicando las métricas obtenidas por el mejor modelo de cada algoritmo. Seleccionar y justificar cuál es el modelo más adecuado para este problema, considerando tanto las métricas como la interpretabilidad.

Presentación

La entrega es por grupos de dos estudiantes y se entrega un archivo por grupo.

Cualquier integrante del grupo puede hacer la entrega mediante el campus de la materia.

El informe deberá tener una cabecera en la que se indique: año, materia, integrantes. Además, deberá contar con una sección de conclusiones al final del mismo.

El formato del informe deberá ser **.ipynb** (Jupyter Notebook) y no debe contener las definiciones teóricas ni el significado de los parámetros de los métodos dados en clase.

Utilizar *random_state=63* en todos los modelos y en las particiones de datos para garantizar la reproducibilidad.

Trabajo Practico N° 2

Minería de datos

Las gráficas mostradas en el informe deben contener una explicación de lo observado y si es coherente con la hipótesis previa. La cantidad de gráficas debe ser acotada (no más de 3-4 por actividad) y representativa.

Las entregas fuera del plazo establecido no serán consideradas salvo excepciones previamente justificadas por el grupo.

Nota: se valorará la correcta interpretación de los resultados, la justificación de las decisiones tomadas y la calidad de las visualizaciones por sobre la cantidad de experimentos realizados.